

Cel projektu

Celem projektu było stworzenie prostego systemu rekomendacji książek z wykorzystaniem perceptronu zaimplementowanego od podstaw w języku Python. Projekt miał pomóc w praktycznym zrozumieniu działania perceptronu oraz sprawdzeniu, czy taki model może zostać wykorzystany do przewidywania, czy użytkownik polubi daną książkę na podstawie wybranych cech.

Aby to osiągnąć, problem został sprowadzony do klasyfikacji binarnej. Na podstawie danych o użytkownikach oraz ocenach książek, model miał przewidywać jedną z dwóch klas:

- 1 - użytkownik polubi książkę,
- -1 - użytkownik nie polubi książki.

Na podstawie działania modelu została następnie przygotowana prosta funkcja rekomendacji książek dla nowego użytkownika. Rekomendacja uwzględnia grupę wiekową użytkownika oraz, jeśli istnieje wystarczająco danych, również jego kraj.

Zbiór danych

W projekcie wykorzystano zbiór danych Book-Crossing: User review ratings, dostępny na platformie Kaggle. Dataset zawiera informacje o użytkownikach, książkach oraz ocenach wystawianych przez użytkowników.

W projekcie wykorzystano przede wszystkim dane dotyczące ocen książek oraz wieku użytkowników. Oceny zostały przekształcone do postaci binarnej, ponieważ perceptron działa na dwóch klasach. Przyjęto następujący podział:

- ocena 7-10 oznacza, że użytkownik polubił książkę,
- ocena 1-6 oznacza, że użytkownik nie polubił książki.

Przed rozpoczęciem uczenia modelu dane zostały dodatkowo przefiltrowane, aby usunąć informacje, które mogłyby okazać się nierzetelne lub mało realistyczne. Usunięto między innymi rekordy, w których ocena książki wynosiła 0, ponieważ taka wartość mogła oznaczać brak oceny. Odrzucono również użytkowników bez podanego wieku oraz osoby poniżej 13 roku życia. Dodatkowo zbiór danych został zawężony do książek posiadających więcej niż 10 ocen w danej grupie wiekowej, dzięki czemu model opierał się na bardziej wiarygodnych średnich ocen, zamiast na pojedynczych, mało

reprezentatywnych rekordach. Celem tych filtracji było przeprowadzenie możliwie najbardziej rzetelnego eksperymentu.

Po dokonanej selekcji danych, użytkownicy zostali podzieleni na grupy wiekowe w poniższych podziałach:

- 13 - 18,
- 19 - 25,
- 26 - 35,
- 36 - 50,
- 51+.

Następnie na podstawie przygotowanych danych utworzono cechy wejściowe dla perceptronu:

- wiek użytkownika,
- średnia ocen książki w danej grupie wiekowej,
- średnia ocen książki ogólnie.

Takie cechy zostały wybrane, ponieważ pozwalały uwzględnić zarówno ogólną popularność książki, jak i preferencje użytkowników należących do podobnej grupy wiekowej. Dzięki temu model mógł próbować przewidywać, czy dana książka może przypaść do gustu użytkownikowi o określonym wieku.

W części odpowiedzialnej za rekomendację wykorzystano również lokalizację użytkownika. Z kolumny "Location" wyodrębniono kraj, który nie został użyty jako bezpośrednia cecha wejściowa perceptronu, ale posłużył do dodatkowego zawężenia rekomendacji. Oznacza to, że dla nowego użytkownika system w pierwszej kolejności próbuje dobrać książkę ocenianą przez osoby z tej samej grupy wiekowej i z tego samego kraju. Ponieważ takie połączenie mocno ogranicza liczbę dostępnych danych, przy rekomendacji uwzględniającej kraj przyjęto niższy próg - książka musi mieć więcej niż 2 oceny w danej grupie wiekowej i kraju. Jeżeli dla takiego połączenia brakuje danych, system wraca do ogólniejszej rekomendacji opartej tylko na grupie wiekowej.

Dobór algorytmu

Do projektu został wybrany perceptron, ponieważ dobrze pasował do problemu przewidywania dwóch możliwych wyników - użytkownik polubi książkę albo jej nie polubi. Dzięki temu możliwe było wykorzystanie klasyfikacji binarnej i sprawdzenie, czy na podstawie wybranych cech model będzie w stanie poprawnie przewidywać preferencje użytkowników.

Pod uwagę brane były również inne algorytmy omawiane podczas zajęć, takie jak BFS, DFS, A* czy Minimax. Ostatecznie nie zostały one wykorzystane, ponieważ są przeznaczone głównie do przeszukiwania grafów lub rozwiązywania problemów związanych z podejmowaniem decyzji w grach. W projekcie potrzebny był natomiast algorytm potrafiący analizować dane wejściowe i przypisywać je do określonych klas, dlatego perceptron okazał się bardziej odpowiednim wyborem do tego zagadnienia.

Działanie metody

Model działa w taki sposób, że dla każdej książki analizuje przygotowane wcześniej dane wejściowe i na ich podstawie próbuje przewidzieć, czy użytkownik może ją polubić. W projekcie wykorzystano trzy cechy: wiek użytkownika, średnią ocen książki w danej grupie wiekowej oraz średnią ocen książki ogólnie.

Na początku działania perceptronu wszystkie wagi ustawiane są na wartość 0. Następnie model przechodzi przez dane treningowe i dla każdego rekordu oblicza wynik na podstawie danych wejściowych, wag oraz biasu. Następnie wynik jest przypisywany do jednej z dwóch, wymienionych uprzednio klas. Jeżeli przewidywanie modelu jest błędne, perceptron aktualizuje swoje wagi i bias. Dzięki temu w kolejnych epokach stopniowo uczy się zależności występujących w danych i próbuje poprawiać skuteczność predykcji.

Dane zostały dodatkowo podzielone na zbiór treningowy oraz testowy w proporcji 80/20. Model uczy się na danych treningowych, natomiast dane testowe służą do sprawdzenia, jak perceptron radzi sobie z rekordami, których wcześniej nie widział.

Po trenowaniu modelu została przygotowana również prosta funkcja rekomendacji książek dla nowego użytkownika. Program pobiera wiek oraz kraj użytkownika, a następnie przypisuje go do odpowiedniej grupy wiekowej. W pierwszej kolejności system próbuje znaleźć książki oceniane przez osoby z tej samej grupy wiekowej i z tego samego kraju. Jeśli dla takiego połączenia nie ma wystarczających danych,

rekomendacja tworzona jest tylko na podstawie grupy wiekowej. Następnie perceptron przewiduje, które książki użytkownik może polubić, a z pozytywnych predykcji wybierana jest najwyższej oceniana propozycja.

Aby ocenić generalną skuteczność modelu, wykorzystano:

- accuracy, czyli dokładność predykcji,
- macierz pomyłek,
- liczbę błędów w kolejnych epokach treningu.

Testy i wyniki

Projekt przechodził przez kilka etapów i w trakcie pracy wielokrotnie zmieniane były wykorzystywane cechy wejściowe. Początkowo model opierał się głównie na wieku użytkownika, średniej ocen oraz popularności książki. W praktyce okazało się jednak, że sam wiek użytkownika miał bardzo mały wpływ na działanie perceptronu i jego waga była bliska zeru. Uznałam więc, że stworzenie rekomendacji opartych o grupy wiekowe nie będzie miało większego sensu. Z tego powodu projekt został przebudowany i przez pewien czas model opierał się głównie na bardziej ogólnych statystykach, takich jak średnia ocen książki, liczba ocen książki oraz średnia ocen wystawianych przez użytkownika. Założenie było takie, że perceptron będzie próbował określić, czy użytkownik ocenia książki bardziej surowo czy łagodnie oraz czy dana książka jest popularna i dobrze odbierana przez innych użytkowników. Było to całkiem skuteczne podejście, ale niewiele miało wspólnego z realną personalizacją - nie ma nic odkrywczego w założeniu, że popularne i lepiej oceniane książki prędzej przypadną również innym do gustu.

Dopiero później zauważyłam jednak, że problem wynikał bardziej ze sposobu przygotowania cech niż z samego wieku użytkownika. Początkowo zbyt „po ludzku” podchodziłam do działania perceptronu i zakładałam, że sam wiek powinien bezpośrednio wpływać na wynik predykcji. Dopiero po czasie zdecydowałam się wykorzystać średnią ocen książki wśród osób z tej samej grupy wiekowej. Takie podejście okazało się znacznie bardziej sensowne i pozwoliło ostatecznie zaimplementować prostą rekomendację książek opartą o preferencje użytkowników w podobnym wieku - co uważam za dużo sensowniejsze podejście w przypadku systemu rekomendacji.

Finalna wersja modelu wykorzystuje więc następujące cechy wejściowe:

- wiek użytkownika,

- średnią ocen książki w danej grupie wiekowej,
- średnią ocen książki ogólnie.

W ostatnim etapie do funkcji rekomendacji dodano także kraj użytkownika. Nie został on jednak potraktowany jako bezpośrednia cecha wejściowa perceptronu, ale jako dodatkowy warunek przy wyborze książek branych pod uwagę w rekomendacji.

Na podstawie przeprowadzonych testów model osiąga skuteczność predykcji na poziomie około 83%. Sama wartość *accuracy* uważam, że jest stosunkowo dobra choć niewiele większa od trafności poprzednich wersji projektu (osiągałam wtedy wynik w okolicach 80%).

Sprawdziłam również wpływ różnych progów ocen na działanie perceptronu. Gdy za klasę pozytywną uznałam jedynie oceny 9–10, skuteczność modelu wyraźnie spadła. Z kolei przy niższym progu, np. od oceny 5, dokładność była bardzo wysoka, jednak większość rekordów trafiała wtedy do klasy pozytywnej, co czyniło podział mniej wartościowym. Ostatecznie jako granicę pomiędzy klasami wybrałam ocenę 7, ponieważ stanowi ona rozsądny kompromis pomiędzy zbyt surowym i zbyt łagodnym podziałem ocen.

W przypadku testów jednostkowych projektu, zaimplementowałam również prosty test sprawdzający poprawność działania perceptronu. Test weryfikuje, czy model potrafi poprawnie uczyć się na prostych danych oraz przypisywać rekordy do odpowiednich klas. Dla pliku `perceptron.py`, zawierającego główną logikę modelu, osiągnięto 100% pokrycia testami. Całkowite pokrycie projektu wynosi jednak 23%, ponieważ testy nie obejmują pliku `main.py`.

Wnioski

Projekt był ciekawym doświadczeniem i pozwolił mi lepiej zrozumieć działanie perceptronu. W trakcie pracy projekt przechodził przez wiele zmian, co momentami było dość frustrujące, ale jednocześnie dało mi dużą satysfakcję pod koniec, gdy doszłam do wniosku, że mój początkowy pomysł miał jednak sens, a jedynie mój sposób myślenia o nim był błędny. Choć przebudowanie projektu wymagało dodatkowej pracy, ostatecznie jestem z niego dużo bardziej zadowolona niż z wcześniejszych wersji, w których jakakolwiek rekomendacja oparta głównie o popularność książki wydawała mi się bezsensowna. Myślę, że trudno było to uznać za prawdziwą rekomendację, jeśli algorytm polecałby książki uznawane ogólnie za dobre, bez tak naprawdę jakiegokolwiek formy personalizacji.

Finalnie udało mi się jednak stworzyć prosty system rekomendacji z delikatną personalizacją opartą na grupach wiekowych użytkowników. Dodatkowo w końcowej wersji projektu uwzględniony został również kraj użytkownika, który służy do zawężenia rekomendacji, jeśli dostępne są odpowiednie dane. Oznacza to, że system najpierw próbuje zaproponować książkę na podstawie grupy wiekowej oraz kraju użytkownika, a jeśli nie ma wystarczającej liczby danych, wraca do ogólniejszej rekomendacji opartej tylko na grupie wiekowej. Myślę, że można uznać ten projekt za prosty, początkowy model rekomendacji dla nowego użytkownika, o którym nie wiadomo jeszcze nic poza jego wiekiem i pochodzeniem.

Zależało mi również, aby projekt był związany z moimi zainteresowaniami i jednocześnie pokazywał realne zastosowanie takiego algorytmu. Myślę, że ostatecznie udało mi się osiągnąć oba te cele.